

LAPORAN PRAKTIKUM MACHINE LEARNING
Analisis Eksperimen Unsupervised Learning,
dan Data Preprocessing
Berdasarkan Buku Introduction to Machine Learning with Python
(Chapter 3)



Dibuat oleh:

Nama : Agief Vemas a

NPM : G1A024037

Kelas : A (Informatika)

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

1. PENDAHULUAN DAN KONSEP DASAR

Pembelajaran tanpa pengawasan atau unsupervised learning merupakan cabang algoritma machine learning di mana data masukan yang diberikan kepada sistem tidak dilengkapi dengan label jawaban, target, ataupun arahan dari pembimbing eksternal. Algoritma dipaksa untuk mengeksplorasi data sendiri demi menemukan pola, struktur tersembunyi, atau keterkaitan bermakna yang terkandung di dalamnya. Secara fungsional, Bab 3 membagi unsupervised learning ke dalam dua kategori besar:

Kategori pertama adalah Unsupervised Transformations atau Transformasi Tanpa Pengawasan. Kategori ini mencakup algoritma yang mengubah representasi data dari bentuk aslinya ke bentuk baru. Tujuan dasarnya bisa berupa reduksi dimensi (mengurangi jumlah fitur agar data lebih mudah diproses atau divisualisasikan), ekstraksi fitur (menemukan komponen penyusun utama dari data), atau pembersihan noise.

Kategori kedua adalah Clustering atau Pengelompokan. Kategori ini mencakup algoritma yang membagi titik-titik data ke dalam beberapa kelompok terpisah berdasarkan tingkat kemiripan karakteristiknya, tanpa mengetahui sebelumnya berapa jumlah kelompok alami yang ada atau apa makna dari kelompok-kelompok tersebut.

2. PRA-PEMROSESAN DAN SKALING DATA (PREPROCESSING & SCALING)

Sebelum menerapkan algoritma unsupervised learning maupun supervised learning tertentu (seperti Support Vector Machines dan Neural Networks), data mentah harus melalui tahap skaling atau penyesuaian skala fitur. Hal ini dikarenakan algoritma yang mengandalkan perhitungan jarak Euclidean atau komputasi bobot matematis sangat sensitif terhadap perbedaan rentang skala antar-fitur. Jika satu fitur memiliki rentang nilai ribuan dan fitur lainnya bernilai desimal antara 0 hingga 1, fitur pertama akan secara tidak proporsional mendominasi seluruh komputasi. Empat Metode Skaling Utama dalam Scikit-Learn:

Pertama, StandardScaler. Metode ini mengubah skala setiap fitur sedemikian rupa sehingga nilai rata-rata (mean) dari fitur tersebut menjadi 0 dan variansnya menjadi 1. Hasil transformasi ini menghasilkan distribusi data berpuncak di angka nol, tetapi tidak menjamin batas nilai minimum atau maksimum tertentu.

Kedua, RobustScaler. Metode ini memiliki tujuan serupa dengan StandardScaler, namun menggunakan nilai median dan interquartile range (kuartil) alih-alih nilai rata-rata dan varians. Pendekatan statistik ini membuat RobustScaler sangat tangguh terhadap adanya outlier atau data pencilan ekstrem yang sering kali merusak hasil skaling standar.

Ketiga, MinMaxScaler. Metode ini menggeser dan mengompresi data sedemikian rupa sehingga seluruh nilai pada setiap fitur berada dalam rentang ketat antara 0 dan 1.

Keempat, Normalizer. Berbeda dengan tiga metode sebelumnya yang bekerja berbasis kolom/fitur, Normalizer bekerja berbasis baris/sampel. Setiap sampel data direskala sedemikian rupa sehingga panjang vektor Euclidean-nya bernilai tepat 1. Metode ini memproyeksikan titik data ke permukaan lingkaran atau bola berjangkauan radius satu. Normalizer umum digunakan ketika arah atau sudut antar-vektor fitur lebih berpengaruh dibanding besaran nilainya. Aturan Krusial Penggunaan Scaler pada Data Latih dan Data Uji:

Salah satu kesalahan paling sering terjadi dalam pra-pemrosesan data adalah mengukur atau melakukan fitting scaler secara terpisah pada data latih (training set) dan data uji (test set). Prinsip dasar yang harus dipatuhi adalah: objek scaler harus dipelajari (ditentukan nilai minimum, maksimum, rata-rata, atau standar deviasinya) HANYA menggunakan data latih melalui perintah fit. Selanjutnya, perintah transform diterapkan pada data latih DAN data uji menggunakan parameter yang telah dipelajari dari data latih tersebut. Jika data uji di-fit secara terpisah, skala dan orientasi relatif data uji terhadap data latih akan rusak, sehingga prediksi model supervised di tahap berikutnya menjadi tidak valid.

3. REDUKSI DIMENSI, EKSTRAKSI FITUR, DAN MANIFOLD LEARNING

Reduksi dimensi adalah teknik untuk memproyeksikan data berdimensi tinggi (memiliki sangat banyak fitur) ke dalam ruang berdimensi lebih rendah dengan tetap mempertahankan informasi terpenting dari data asli.

A. Principal Component Analysis (PCA)

Principal Component Analysis atau PCA adalah metode linear yang memutar sumbu koordinat data ke arah varians maksimum.

Proses kerjanya dimulai dengan mencari arah dalam ruang fitur asli yang memiliki varians atau sebaran data paling besar; arah ini disebut Komponen Utama Pertama (First Principal Component). Selanjutnya, PCA mencari arah kedua yang tegak lurus (orthogonal) terhadap komponen pertama dan memiliki varians terbesar sisanya; arah ini disebut Komponen Utama Kedua. Proses ini berlanjut hingga jumlah komponen sama dengan jumlah fitur asli.

Dua Aplikasi Utama PCA:

Aplikasi pertama adalah Visualisasi Data. Pada dataset berdimensi tinggi, sangat sulit bagi manusia untuk memahami keterkaitan antar-sampel. Melalui PCA, dataset seperti Breast Cancer Dataset (yang memiliki 30 fitur klinis) dapat diproyeksikan menjadi hanya 2 komponen utama. Ketika plotted pada grafik dua dimensi, data tumor jinak dan ganas langsung terpisah secara visual dengan sangat jelas.

Aplikasi kedua adalah Ekstraksi Fitur (Eigenfaces). Pada data citra seperti Labeled Faces in the Wild dataset, setiap piksel foto dihitung sebagai satu fitur. Mengukur jarak langsung antar-piksel sangatlah tidak efektif karena pergeseran posisi foto sebanyak satu piksel saja dapat merubah nilai jarak secara drastis. Dengan menerapkan PCA, piksel-piksel gambar diubah menjadi kombinasi komponen wajah utama yang disebut Eigenfaces. Ketika klasifikasi K-Nearest Neighbors diterapkan pada komponen hasil PCA ini, akurasi pengenalan wajah meningkat secara drastis.

B. Non-Negative Matrix Factorization (NMF)

NMF adalah teknik reduksi dimensi non-linear di mana matriks data diurai menjadi kombinasi komponen-komponen yang seluruh nilainya diwajibkan berupa angka non-negatif (nol atau positif). Karakteristik non-negatif ini membuat NMF sangat cocok untuk ekstraksi topik dari dokumen teks (topic modeling) atau identifikasi bagian-bagian penyusun pada sinyal audio dan gambar, karena komponen yang dihasilkan bersifat aditif (saling menambahkan) sehingga lebih mudah diinterpretasikan oleh manusia.

C. Manifold Learning dengan t-SNE

t-Distributed Stochastic Neighbor Embedding (t-SNE) adalah algoritma manifold learning non-linear yang dirancang khusus untuk visualisasi data berdimensi tinggi pada ruang 2D atau 3D. Berbeda dengan PCA yang berusaha mempertahankan varians global, t-SNE berfokus pada mempertahankan jarak lokal antar-titik data yang berdekatan. Titik-titik data yang serupa di ruang berdimensi tinggi akan dipaksa untuk tetap berdekatan di ruang 2D. Namun, t-SNE umumnya hanya digunakan untuk eksplorasi dan visualisasi data, bukan sebagai tahap pra-pemrosesan untuk model prediksi baru, karena algoritma ini tidak dapat memproyeksikan titik data uji baru tanpa menjalankan ulang seluruh proses dari awal.

4. ALGORITMA CLUSTERING (PENGELOMPOKAN)

Clustering bertujuan membagi kumpulan data ke dalam kelompok-kelompok titik yang serupa, di mana anggota dalam satu kelompok memiliki kemiripan yang tinggi dan sangat berbeda dengan anggota dari kelompok lain.

Analisis Tiga Algoritma Utama:

Pertama, k-Means Clustering.

k-Means bekerja dengan menentukan jumlah k kelompok di awal. Algoritma menempatkan k titik pusat acak (centroids), membagikan setiap titik data ke centroid terdekat, lalu memperbarui posisi centroid berdasarkan nilai rata-rata dari seluruh titik data di kelompok tersebut. Proses ini diulang hingga posisi centroid stabil.

Kelebihannya: Sangat cepat, mudah dipahami, dan efisien untuk himpunan data skala besar.

Kekurangannya: Pengguna harus menentukan jumlah k secara manual di awal, sensitif terhadap inisialisasi awal centroid, dan hanya mampu menemukan kelompok berbentuk bola/lingkaran simetris (gagal pada bentuk-bentuk kompleks seperti pola bulan sabit).

Kedua, Agglomerative Clustering.

Algoritma ini menggunakan pendekatan hierarki dari bawah ke atas (bottom-up). Setiap titik data diawali sebagai satu kelompok tersendiri. Secara bertahap, dua kelompok yang paling mirip atau berdekatan digabungkan menjadi satu kelompok yang lebih besar, hingga tersisa sejumlah kelompok yang diinginkan.

Kelebihannya: Menghasilkan struktur kelompok berhierarki yang dapat divisualisasikan menggunakan diagram pohon (dendrogram).

Kekurangannya: Sangat berat secara komputasi sehingga kurang efisien untuk dataset dalam skala ribuan atau jutaan sampel.

Ketiga, DBSCAN (Density-Based Spatial Clustering of Applications with Noise).

DBSCAN bekerja berdasarkan tingkat kerapatan lokal titik data. Algoritma ini menentukan titik inti (core points) jika terdapat sejumlah sampel minimum (min_samples) dalam radius jarak tertentu (eps).

Kelebihannya: Tidak memerlukan penentuan jumlah kelompok di awal, sanggup menemukan bentuk kelompok yang sangat rumit dan tidak teratur, serta mampu mengidentifikasi titik-titik data yang tidak termasuk ke kelompok mana pun sebagai noise atau outlier.

Kekurangannya: Sangat sensitif terhadap penentuan nilai parameter eps dan min_samples .

5. TANTANGAN DAN EVALUASI PADA UNSUPERVISED LEARNING

Tantangan terbesar dalam unsupervised learning adalah ketiadaan label acuan kebenaran (ground truth). Tanpa adanya jawaban yang pasti, mengukur apakah sebuah model telah memberikan hasil yang "benar" atau "bagus" menjadi sangat sulit.

Cara Evaluasi dan Metrik:

1. Pemeriksaan Manual dan Eksplorasi Visual.

Sering kali, cara terbaik dan utama untuk menilai keberhasilan model unsupervised adalah melalui analisis kualitatif oleh pakar bidang (domain expert) atau pemeriksaan visual hasil proyeksi reduksi dimensi dan pembagian kelompok.

2. Evaluasi Tanpa Label (Metrik Internal).

Metrik seperti Silhouette Coefficient mengukur seberapa rapat titik-titik dalam satu kelompok dibandingkan dengan jarak ke kelompok tetangganya. Namun, nilai Silhouette yang tinggi tidak selalu berarti pengelompokan tersebut berguna untuk konteks bisnis tertentu.

3. Evaluasi Dengan Label Acuan (Metrik Eksternal untuk Pengujian Eksperimental).

Dalam skenario eksperimen di mana label sebenarnya tersedia namun sengaja disembunyikan dari algoritma, kualitas clustering dapat diukur menggunakan Adjusted Rand Index (ARI) atau Normalized Mutual Information (NMI). Metrik ini mengukur seberapa cocok hasil clustering dengan susunan kelas sebenarnya, terlepas dari perbedaan penamaan label angka kelompok.

6. KESIMPULAN DAN RINGKASAN PRAKTIS

Pra-pemrosesan melalui pembersihan dan skaling data adalah fondasi awal yang wajib dilakukan untuk memastikan algoritma pemodelan downstream dapat bekerja secara optimal. Reduksi dimensi seperti PCA sangat berguna untuk menyederhanakan kompleksitas data, menghilangkan noise, serta memvisualisasikan struktur data berdimensi tinggi ke dalam format 2D. Pemilihan algoritma clustering harus disesuaikan dengan kebutuhan permasalahan: k-Means dipilih untuk kesederhanaan dan skala data besar, Agglomerative untuk analisis hierarki, dan DBSCAN untuk menemukan pola kelompok spasial yang rumit serta menangani outlier.